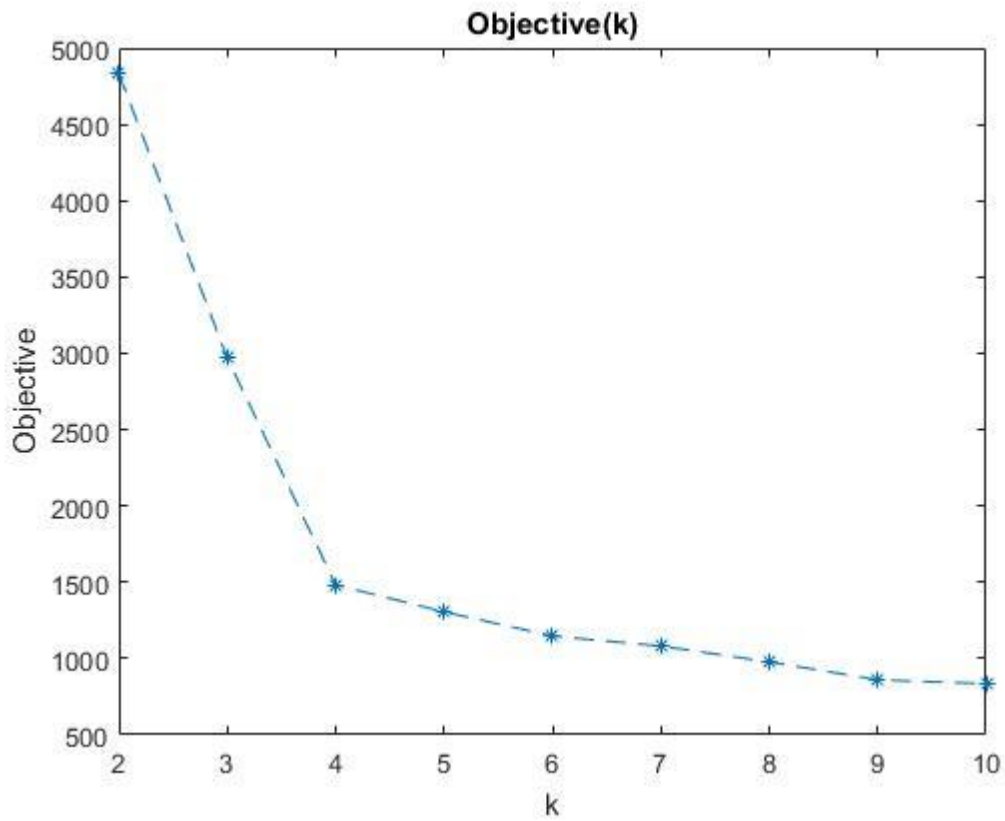


1.b.







The objective decreases in k. This is logical if we look at the objective formula:

$$G_{k-m}(C_1, \dots, C_k) = \sum_{i=1}^k \sum_{x \in C_i} \left\| x - \frac{1}{|C_i|} \sum_{x \in C_i} x \right\|^2$$

As k increases, each example has a center that is closer to it, so the summation of all distances will be smaller in the end.

1. c.





By looking at the dataset, we can observe that the points generally divide into four groups. Therefore, $k=4$ is the most logical clustering (this can also be clearly seen in the figure for $k=4$). This is not the clustering with the smallest value of the k-means objective.

1.d.

By looking at the formula for the k-means objective, we can see that with high probability, the objective decreases in k regardless of the dataset. However, the most logical clustering is not always the one with the most number of clusters.

1.e.

Cluster	Most common label	Percentage of common label in Cluster (%)
1	7	91.0448
2	1	66.0606
3	6	71.1712
4	0	86
5	4	50
6	9	40.2878
7	8	54.8077
8	3	54.7445
9	0	91.8367
10	2	89.1892

1.f.


The classification error on the sample resulting from a classifier derived from the above clusters

Is: 0.357 this calculation was done by the following matlab calculation:

```
percentages = zeros(1, 10);
modes = zeros(1, 10);
Ypredict = zeros(size(C));
for i = 1:10
    labels = Y(C==i);
    modes(i) = mode(labels);
    percentages(i) = sum(labels==modes(i)) / size(labels,1) * 100.0;
    Ypredict = Ypredict + (C==i)*modes(i);
end
errs(j) = mean(Y ~= Ypredict);
```


with C being the clusters array returned from the K-means, And Y being the original labels.

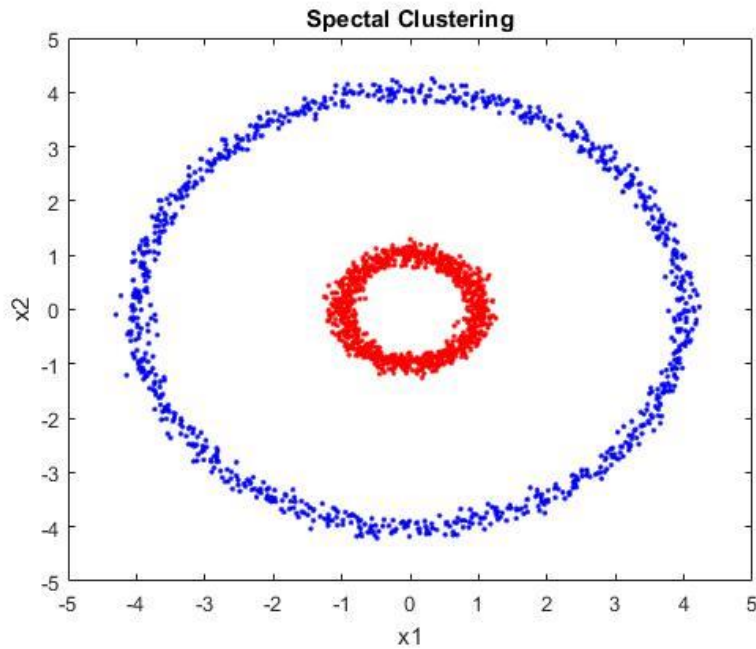
2.b.



k-means will find the clusters in which the points are closest to their center. In this case this will not output the desired outcome since the outer circle would never be identified as one cluster.

2. c.





K-means Clustering tries to minimize the distances from each point to its cluster's center. Therefore, it "splits" the image in 2.

Spectral Clustering tries to minimize the variance of its clusters. Therefore, it identifies each circle as a cluster.

3.

$$③ X \in \mathbb{R}, Y \in \mathbb{R}, Y \sim N(3X, 5\hat{\sigma}^2)$$

אם ההצבה, $\hat{\sigma}^2$ ו-3 נכנסות מונות $h^*: X \rightarrow Y$ ההכאה הנכונה

$$E_{(X,Y) \sim D} [l(h(X), Y)]$$

$$E_{(X,Y) \sim D} (l(h(X), Y)) = E_{(X,Y) \sim D} ((h(X) - Y)^2) =$$

$$= E_X (E_Y ((h(X) - Y)^2)) = E_X (E_Y (h^2(X) - 2h(X) \cdot Y + Y^2)) =$$

$$\left(\begin{array}{l} \text{הכאה נכונה} \\ \text{ל-} Y \end{array} \right) = E_X (E_Y (h^2(X)) - E_Y (2h(X) \cdot Y) + E_Y (Y^2))$$

$$\left(\begin{array}{l} \text{הכאה נכונה} \\ \text{ל-} X \end{array} \right) = E_X (h^2(X) - 2h(X) E_Y (Y) + E_Y (Y^2))$$

$$(*) = E_X (h^2(X) - 2h(X) \cdot 3X + 14X^2) = E_X (h^2(X) - 6X \cdot h(X) + 14X^2)$$

$$X \in \mathbb{R} \quad h^*(X) \quad \text{הכאה נכונה} \quad h^2(X) - 6X \cdot h(X) + 14X^2 \quad \text{הכאה נכונה} \quad \text{ל-} Y$$

כאשר $X \in \mathbb{R}$, אנו רוצים להחליט על h^* הכאה נכונה.

$$g(h(X)) = h^2(X) - 6X \cdot h(X) + 14X^2$$

$$g'(h(X)) = 2h(X) - 6X = 0 \Rightarrow h^*(X) = 3X$$

$$g''(h^*(X)) = 2 > 0$$

Bayes-Optimal הכאה $h^*(X) = 3X$ נכונה

, $E_Y(Y) = 3X$ נכונה, $Y \sim N(3X, 5\hat{\sigma}^2)$ (*)

$$E_Y(Y^2) = V(Y) + E^2(Y) = 5X^2 + 9X^2 = 14X^2$$

4.a.

(4) c)

נאכת' שהבט' קלמורה:

34

הפונקציה $B = \{x \in \mathbb{R}^d \mid Wx = y\}$ היא

$\exists \delta \in \mathbb{R}^+ : \forall u, v \in \mathbb{R}^d : |u - v| \leq \delta \Rightarrow |f(u) - f(v)| \leq \epsilon$

$$W(u + (1-q)v) = \alpha W_u + (1-q)W_v = \alpha \gamma + (1-q)\gamma = \gamma$$

$\exists v \in B \quad \alpha \cdot h + (1 - \alpha) \cdot v \in B$

נוכח שהפונקציה $f: B \rightarrow \mathbb{R}$ הנמשכת \bar{B} היא $f(w) = \|w\|_1$ קמורה:

$$f(\alpha u + (1-\alpha)v) = \|\alpha u + (1-\alpha)v\|_1 \leq \|\alpha u\|_1 + \|(1-\alpha)v\|_1$$

(equality, e.g.)

$$= \alpha \|u\|_1 + (1-\alpha) \|v\|_1 = \alpha f(u) + (1-\alpha) f(v)$$

סדר העולה, מלמעלה למטה

$$\max. \langle u, x \rangle$$

מאכלי חלב ודבש

$$\text{s.t. } Ax \geq r$$

$$u = (\underbrace{0, 0, \dots, 0}_d, \underbrace{1, 1, \dots, 1}_d)$$

3. $\frac{1}{2}$

$$A_{(2k+2d) \times 2d} = \begin{pmatrix} W_{k \times d} & 0_{k \times d} \\ -W_{k \times d} & 0_{k \times d} \\ -I_{d \times d} & I_{d \times d} \\ I_{d \times d} & I_{d \times d} \end{pmatrix}, \quad v_{2k+2d \times 1} = \begin{pmatrix} \gamma_{k \times 1} \\ -\gamma_{k \times 1} \\ 0_{d \times 1} \\ 0_{d \times 1} \end{pmatrix}$$

$x = (x_1, x_2, \dots, x_d, \xi_1, \xi_2, \dots, \xi_d) : \text{point} : \underline{\text{input}}$

$$, \langle n, X \rangle = \sum_{i=1}^d -\epsilon_i$$

רע-ס-ט כי המונח ממונה

$$\sum_{i=1}^n \epsilon_i$$
$$W_{\bar{x}} = Y \quad p.d. \quad \varepsilon_i = |x_i| \quad ; 1 \leq i \leq d \quad \delta > \delta \quad \text{so} \quad p' > p \quad \bar{x} = (x_1, \dots, x_d)$$

Constraints \rightarrow $W\bar{x} \geq \gamma$ and $-W\bar{x} \geq -\gamma$: "primal" form

$$\Rightarrow W\bar{x} \geq r \quad \vee \quad W\bar{x} \leq r$$

$$\Rightarrow W_{\bar{x}} = 4$$

$$\forall 1 \leq i \leq d: -x_i + \varepsilon_i \geq 0 \wedge x_i + \varepsilon_i \leq 0$$

2018, 11, 11

$$\Rightarrow \neg \exists x_1 \exists x_2 (x_1 \geq x_2 \vee x_1 \geq -x_2)$$

$$\Rightarrow \varepsilon_i \geq \max\{x_i, -x_i\} = |x_i|$$

ה'אור ואנחנו נביאים יחד ξ_i מ'נ'נ'נ'נ'נ'נ' $|x| = \xi_i$ ו'א'נ'נ'נ'נ'נ'נ' ξ_i .

4.b.

④) א"י $f(x) = \|x\|_0$ $f: B \rightarrow \mathbb{R}$ f B \mathbb{R} f B \mathbb{R} f B \mathbb{R}

קמ"ר:

$$d=2, K=1, W=(0,0), Y=0, u=(1,0), v=(1,1), \alpha=\frac{1}{2}$$

יציאת:

$$u, v \in B \quad \text{כ"י} \quad u, v \in \mathbb{R}^d \quad \text{כ"י} \quad \text{כ"י}$$

$$f(\alpha u + (1-\alpha)v) = \left\| \frac{1}{2}(1,0) + \frac{1}{2}(1,1) \right\|_0 = \left\| (1, \frac{1}{2}) \right\|_0 = 2$$

כ"י:

$$\alpha f(u) + (1-\alpha)f(v) = \frac{1}{2} \|(1,0)\|_0 + \frac{1}{2} \|(1,1)\|_0 = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 2 = \frac{3}{2}$$

$$f(\alpha u + (1-\alpha)v) > \alpha f(u) + (1-\alpha)f(v)$$

מק"א

f B \mathbb{R} f B \mathbb{R} f B \mathbb{R}

5.a.

נמצא את הבסיס של מטריצה A המעבר A לתוך \mathbb{R}^m : (5)

$$A = \arg \min_{W \in \mathbb{R}^{d \times d}, \det(A) \neq 0} \left(\sum_{i=1}^m \|Wx_i\|_0 \right)$$

ה"תיון הפיכה זו הוא שאם נצטיק לפעולה את כל המצבים, המידע שניאלץ לפעולה יהיה מ'ני'לם'. התסכון הוא שאם נצטיק לפעולה x -ים מסוי'מים יותר פעמים מאחרים, זהו לא הכרחי האובס'לם' (ניתן למצוא בסיס אחר יותר ז' מתן שוקם שונה x -ים שונים)

5.b. ה-transmitter יחב את מטריצה המעבר A ממרחב \mathbb{R}^d (5)

למרחב של בסיס B ו'חב את Ax לכל מס'ול. כעו
לכל $Ax_{(j)} \neq 0$ הוא ישלח שלח: $(j; i, j, x)$.

ה'י'נין המ'צע הנ'ל, ה-receiver יחבר את המ'צם במ'לואו
בבסיס B . כעו הוא יכ'צד Compressed Sensing ע'ל מ'נר למ'צא
"צול ד'ל'ל S . כלומר, הוא יל'ל למ'צ'ד G המ'ל'צד $d \times k$
כאשר k הוא מ'ג תת-המ'צם הנ'מן, ו'כ'ל אומר כ'ל אחד
מא'ב'י המ'צם. בהסת'כוה ל'בורה (ק.ח.ש) המ'צ'ד, שהוט'לה
ת'ה' RIP ול'כן המ'צע י'ד'בור ע'יצול ד'ל'ל (א'צ'מ) אשר נ'מ
ל'חבר מ'מנו ז'ור S כול'ה.

נ'ט'ע-ע' ש'ור מ'ש'אור בפ'ל'חה, הש'אור י'כול ע'כ'יו'ר רק
בה'ל'ל'ר המ'צ'ת ה-RIP, ול'זו אומר הש'אור ש'ע'ל'ה ע'ק'חור
כא'ל'ל'ר אונ'ל'מ' ש'בו ה-receiver י'צ'ד את S ומ'נסה ל'ה'ע'ב'יו
ע'יצול ד'ל'ל.

6.a.

6a) נמצא את התבונה של $f_2(x) = e^{-\lambda x}$ ונבדוק

$$\int_0^{\infty} f_2(x) dx = 1$$

$$\Rightarrow \int_0^{\infty} C_2 e^{-\lambda x} dx = 1$$

$$C_2 \int_0^{\infty} e^{-\lambda x} dx = 1$$

$$C_2 \left(\frac{e^{-\lambda x}}{-\lambda} \right) \Big|_0^{\infty} = 1$$

$$C_2 \left(0 + \frac{1}{\lambda} \right) = 1$$

$$\boxed{C_2 = \lambda}$$

6b) $f_2(x) = \lambda e^{-\lambda x}$

$$L(s; \lambda) = \sum_{i=1}^n \log f_2(x_i) = \sum_{i=1}^n \log(\lambda e^{-\lambda x_i}) = \sum_{i=1}^n (\log \lambda + \log e^{-\lambda x_i})$$

$$= \cancel{n \log \lambda} - \lambda \sum_{i=1}^n x_i$$

$$L'(s; \lambda) = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$$

לגזור כדי למצוא נקודת מרבי

$$\Rightarrow \lambda = \frac{n}{\sum_{i=1}^n x_i}$$

$$L''(s; \lambda) = -\frac{n}{\lambda^2} < 0$$

נוכח שזהו נקודת מקסימום

לכן ה- λ המצוינה היא המומינת

$$\boxed{\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i}}$$